

HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY
SCHOOL OF INFORMATION TECHNOLOGY AND COMMUNICATION

— o0o —



NVIDIA Agent Intelligence Toolkit Report

Vuong Le Binh Duong - 20226035

Mục lục

1	Giới thiệu và mục tiêu	4
1.1	Bối cảnh	4
1.2	Mục tiêu	4
2	Công nghệ và Framework sử dụng	4
2.1	Core Framework	4
2.2	AI Models Services	5
2.3	Vector Database Storage	5
2.4	Document Processing	6
2.5	Infrastructure Deployment	6
3	TỔNG QUAN CÁC CÔNG CỤ	7
3.1	NVIDIA NeMo Agent Toolkit (NAT)	7
3.1.1	Giới thiệu	7
3.1.2	Ưu điểm trong dự án	7
3.2	Milvus Vector Database	7
3.2.1	Giới thiệu	7
3.2.2	Vai trò trong RAG pipeline	8
3.3	NVIDIA AI Services	8
3.3.1	NVIDIA NIM (NVIDIA Inference Microservices)	8
3.3.2	NVIDIA Embeddings (NV-EmbedQA-E5-V5)	8
3.4	LangChain Framework	9
3.4.1	Vai trò	9
3.5	Docker & Infrastructure	9
3.5.1	Containerization Stack	9
4	Kiến trúc hệ thống	9
4.1	Tổng quan kiến trúc	10
5	Chi tiết triển khai	12
5.1	Thiết lập môi trường	12
5.2	Database setup	13
5.3	Agent Workflow Configuration	14
5.3.1	NAT YAML Configuration	14
5.4	Server UI Deployment	15
5.4.1	NAT Server Launch	15
5.4.2	Frontend Configuration	15

6	Kết quả và đánh giá	15
6.1	Metric Sử Dụng	15
6.2	Cấu Hình Hệ Thống	15
6.3	Phân Tích Bộ Test	16
6.3.1	Bộ Test Gốc (questions.json)	16
6.3.2	Bộ Test Nâng Cấp (questions2.json)	17
6.4	Tóm tắt phân tích so sánh	18
6.4.1	Điểm mạnh đã được xác nhận	18
6.4.2	Điểm yếu được bộc lộ	19
6.4.3	Ngưỡng độ khó được xác định	19
7	Demo UI	19
8	Kết luận	20

1 Giới thiệu và mục tiêu

1.1 Bối cảnh

Trong thời đại số hóa hiện nay, các doanh nghiệp phải đối mặt với lượng lớn dữ liệu phi cấu trúc từ tài liệu, báo cáo, và quy trình nội bộ. Việc truy xuất thông tin hiệu quả từ các nguồn dữ liệu này trở thành thách thức lớn, đòi hỏi các giải pháp công nghệ tiên tiến.

1.2 Mục tiêu

- Mục tiêu chính: Triển khai hệ thống hỏi đáp trên dữ liệu doanh nghiệp sử dụng NVIDIA Agent Toolkit
- Mục tiêu cụ thể:
 - Xây dựng pipeline xử lý và lưu trữ tài liệu đa định dạng (PDF, DOCX, XLSX, CSV)
 - Tích hợp AI Agent với khả năng reasoning và tool-calling
 - Phát triển giao diện người dùng thân thiện cho tương tác
 - Đảm bảo hiệu suất và độ chính xác cao trong truy vấn

2 Công nghệ và Framework sử dụng

2.1 Core Framework

Công nghệ	Phiên bản	Vai trò	Chức năng
NVIDIA NeMo Agent Toolkit (NAT)	1.1.2	Framework chính	• Có sẵn các mẫu agent (ReAct, Tool-calling) • Tích hợp trực tiếp với NVIDIA AI services • Cấu hình bằng file YAML đơn giản
LangChain	0.3.27	Document processing	• Hỗ trợ đa dạng loaders • Text splitting tối ưu • Tích hợp vector stores

2.2 AI Models Services

Thành phần	Model/Service	Cấu hình	Chức năng
Large Language Model (LLM)	Meta Llama 3.1 70B Instruct	• NVIDIA NIM • Temperature: 0.0 • Max tokens: 1024	Sinh câu trả lời
Embedding Model	NVIDIA NV-EmbedQA-E5-V5	• Truncate: END	Chuyển đổi text thành vector
Agent Pattern	ReAct (Reasoning + Acting)	• Max retries: 3 • Verbose mode: true	Xử lý logic reasoning

2.3 Vector Database Storage

Thành phần	Service	Cấu hình	Chức năng
Vector Database	Milvus v2.6.0	• Port: 19530 • Collection: "my_docs" • Top-k: 3	Lưu trữ và tìm kiếm vector
Metadata Store	etcd v3.5.18	• Auto compaction • Quota: 4GB	Metadata cho Milvus
Object Storage	MinIO	• Ports: 9000, 9001 • Verbose mode: true	Object storage cho Milvus

2.4 Document Processing

Định dạng	Loader	Thư viện	Đặc điểm
PDF	PyPDFLoader	pypdf>=4.2.0	Xử lý text extraction, hỗ trợ metadata
DOCX	Docx2txtLoader	langchain-community	Microsoft Word format
XLSX	StructuredDataLoader (Custom)	pandas + openpyxl	Multi-sheet support
CSV	StructuredDataLoader (Custom)	pandas	Multi-encoding support

2.5 Infrastructure Deployment

Thành phần	Service	Cấu hình	Chức năng
Containerization	Docker Compose		Orchestration
Web Server	FastAPI	Uvicorn/Port: 8000	API endpoints
Frontend	Next.js (NAT-UI)	Port: 3000	User interface

3 TỔNG QUAN CÁC CÔNG CỤ

3.1 NVIDIA NeMo Agent Toolkit (NAT)

3.1.1 Giới thiệu

Developer: NVIDIA Corporation

Mục đích: NAT là framework mã nguồn mở hỗ trợ xây dựng AI agents, workflows và pipelines cho ứng dụng thực tế. **Đặc điểm nổi bật:**

- **Declarative configuration:** Quản lý agents và workflows bằng YAML, dễ mở rộng và tái sử dụng.
- **Built-in agent patterns:** Tích hợp sẵn các mô hình điều phối agent như *ReAct*, *Tool-calling*, *ReWOO*.
- **Native NVIDIA integration:** Hỗ trợ trực tiếp các dịch vụ NVIDIA AI (NIM, Embeddings, Riva...).
- **Extensible Tooling:** Cho phép thêm công cụ tùy chỉnh như REST APIs, cơ sở dữ liệu, hoặc vector stores.

Trong dự án này, NAT được xem như “bộ xương sống” của hệ thống, nơi điều phối luồng xử lý giữa LLM, vector database và các công cụ khác. Thay vì tự xây dựng từ đầu, việc tận dụng NAT cho phép triển khai nhanh agent theo các pattern chuẩn như ReAct và tool-calling, đồng thời tích hợp liền mạch với NVIDIA NIM và dịch vụ embedding. Điều này giúp hệ thống vừa dễ mở rộng vừa phù hợp cho môi trường production.

3.1.2 Ưu điểm trong dự án

- Giảm độ phức tạp khi xây dựng agent workflows nhờ declarative YAML config.
- Kết nối trực tiếp và “seamless” với **NVIDIA NIM** và dịch vụ embedding.
- Hỗ trợ **production-ready deployment** với FastAPI server tích hợp sẵn, dễ dàng đưa lên cloud hoặc on-premise.
- Logging, tracing và observability hỗ trợ sẵn, giúp dễ dàng debug và giám sát agent trong môi trường thực tế.

3.2 Milvus Vector Database

3.2.1 Giới thiệu

Developer: Zilliz, quản lý bởi LF AI & Data Foundation

Mục đích: Cơ sở dữ liệu vector mã nguồn mở, thiết kế chuyên biệt cho AI applications. **Đặc điểm:**

-
- **Cloud-native architecture:** Distributed, elastic scaling.
 - **Storage engine:** Hỗ trợ lưu trữ vector + metadata dạng JSON.
 - **Indexing:** IVF, HNSW, DiskANN cho hiệu năng tìm kiếm cao.
 - **High availability:** Sử dụng etcd cho metadata và MinIO cho object storage.
 - **Phiên bản sử dụng:** v2.6.0

3.2.2 Vai trò trong RAG pipeline

- **Vector Storage:** Lưu trữ embeddings của document chunks sinh ra từ NVIDIA Embeddings.
- **Similarity Search:** Hỗ trợ semantic retrieval bằng cosine similarity hoặc inner product.
- **Metadata Support:** Lưu trữ thông tin nguồn (filename, page number, section).
- **Performance:** Sub-second retrieval trên hàng triệu vectors, tối ưu cho large-scale RAG.

3.3 NVIDIA AI Services

3.3.1 NVIDIA NIM (NVIDIA Inference Microservices)

- **Mô tả:** Nền tảng inference trên cloud, tối ưu cho production AI.
- **Model sử dụng:** Meta Llama 3.1 70B Instruct, cung cấp chất lượng trả lời ngang ngửa SOTA.
- **Ưu điểm:**
 - Tối ưu hóa cho GPU NVIDIA.
 - Độ tin cậy cao, hỗ trợ enterprise-grade SLAs.
 - Khả năng scale linh hoạt với multi-endpoint deployment.

3.3.2 NVIDIA Embeddings (NV-EmbedQA-E5-V5)

- **Mô tả:** Embedding model tối ưu cho Q&A và retrieval tasks.
- **Đặc điểm kỹ thuật:**
 - **Dimension:** 1024
 - **Max input length:** 512 tokens
 - **Multilingual:** Hỗ trợ tiếng Anh, Việt và nhiều ngôn ngữ khác.
 - **Optimized:** Cho semantic retrieval, RAG pipelines và knowledge-intensive tasks.

3.4 LangChain Framework

3.4.1 Vai trò

- **Document Processing:** Loaders cho PDF, DOCX, XLSX, CSV.
- **Text Splitting:** RecursiveCharacterTextSplitter để chia nhỏ tài liệu.
- **Vector Store Integration:** Kết nối trực tiếp với Milvus thông qua langchain-milvus connector.
- **Chain Abstractions:** Đơn giản hóa xây dựng RAG pipeline bằng các chain có sẵn (RetrievalQA, ConversationalRetrievalChain).

```
import pandas as pd
from langchain_community.document_loaders import PyPDFLoader,
    Docx2txtLoader
from langchain_core.documents import Document
from langchain_text_splitters import RecursiveCharacterTextSplitter
from langchain_milvus import Milvus
from langchain_nvidia_ai_endpoints import NVIDIAEmbeddings
```


3.5 Docker & Infrastructure

3.5.1 Containerization Stack


- **Docker Compose:** Orchestration multi-service (Milvus, etcd, MinIO, NAT server).
- **etcd:** Distributed key-value store cho Milvus metadata.
- **MinIO:** S3-compatible object storage, lưu dữ liệu blob/document.
- **Health Checks:** Giám sát dịch vụ tự động, đảm bảo fault-tolerance.
- **Networking:** Các container liên kết qua Docker network để tối ưu latency.
- **Scalability:** Dễ dàng mở rộng bằng cách scale số lượng replicas.

4 Kiến trúc hệ thống


4.1 Tổng quan kiến trúc



Hình 1: Tổng quan kiến trúc



Hình 2: Tổng quan kiến trúc



Hình 3: Tổng quan kiến trúc

5 Chi tiết triển khai

5.1 Thiết lập môi trường

Tải dependencies:

```
# Core NAT framework
pip install -e .
```

```
# Demo-specific dependencies
pip install -r demo_bundle/requirements-demo.txt
```

5.2 Database setup

Khởi động Milvus Infrastructure

```
(base) (.venv) PS D:\NeMo-Agent-Toolkit> PowerShell -NoProfile -
    ExecutionPolicy Bypass -File demo_bundle\scripts\start_milvus.ps1

Starting Milvus using demo_milvus.yml in D:\NeMo-Agent-Toolkit\
demo_bundle                                level=warning msg="D:\\
NeMo-Agent-Toolkit\\demo_bundle\\demo_milvus.yml: the attribute '
version' is obsolete, it will be ignored, please remove it to avoid
potential confusion"
[+] Running 3/3
    Container milvus-standalone   Removed0.0s
    Container milvus-etcd         Removed0.0s
    Container milvus-minio        Removed0.0s

[+] Running 3/3
    Container milvus-minio        Started0.5s
    Container milvus-etcd         Started0.3s
    Container milvus-standalone   Started0.6s
Waiting for Milvus health endpoint...
Milvus is healthy
```

Document Ingestion

```
(base) (.venv) PS D:\NeMo-Agent-Toolkit> cd demo_bundle
(base) (.venv) PS D:\NeMo-Agent-Toolkit\demo_bundle> PowerShell -
    NoProfile -ExecutionPolicy Bypass -File scripts\demo_ingest.ps1
Ingesting D:\NeMo-Agent-Toolkit\demo_bundle\data\2304.08485v2 (1).pdf ->
    Milvus http://localhost:19530
Loaded 122 chunks from D:\NeMo-Agent-Toolkit\demo_bundle\data\2304.08485
v2 (1).pdf
Successfully ingested 122 chunks into collection 'my_docs'
Ingesting D:\NeMo-Agent-Toolkit\demo_bundle\data\2306.00890v1 (1).pdf ->
    Milvus http://localhost:19530
Loaded 74 chunks from D:\NeMo-Agent-Toolkit\demo_bundle\data\2306.00890
v1 (1).pdf
Successfully ingested 74 chunks into collection 'my_docs'
Ingesting D:\NeMo-Agent-Toolkit\demo_bundle\data\2407.21783v3.pdf ->
    Milvus http://localhost:19530
```

```
Loaded 463 chunks from D:\NeMo-Agent-Toolkit\demo_bundle\data\2407.21783
v3.pdf
Successfully ingested 463 chunks into collection 'my_docs'
```

5.3 Agent Workflow Configuration

5.3.1 NAT YAML Configuration

```
general:
  use_uvloop: true

embedders:
  milvus_embedder:
    _type: nim
    model_name: nvidia/nv-embedqa-e5-v5
    truncate: "END"

retrievers:
  my_retriever:
    _type: milvus_retriever
    uri: http://localhost:19530
    collection_name: "my_docs"
    embedding_model: milvus_embedder
    top_k: 3

functions:
  my_retriever_tool:
    _type: nat_retriever
    retriever: my_retriever
    topic: Retrieve company documents

llms:
  nim_llm:
    _type: nim
    model_name: meta/llama-3.1-70b-instruct
    temperature: 0.0
    max_tokens: 1024
    api_key: $NVIDIA_API_KEY

workflow:
  _type: react_agent
  tool_names:
    - my_retriever_tool
  llm_name: nim_llm
  verbose: true
```

```
parse_agent_response_max_retries: 3
```

5.4 Server UI Deployment

5.4.1 NAT Server Launch

```
cd demo_bundle
$env:NVIDIA_API_KEY = "YOUR_API_KEY"
# Start NAT server
nat serve --config_file=workflow.yaml
```

5.4.2 Frontend Configuration

```
# Navigate to UI directory
cd external/nat-ui

# Install dependencies
npm install

# Launch development server
npm run dev # Available at http://localhost:3000
```

6 Kết quả và đánh giá

6.1 Metric Sử Dụng

- **Metric chính:** RAGAS AnswerAccuracy
- **Thang điểm:** 0.0 – 1.0 (1.0 = Perfect match)
- **Judge LLM:** mistralai/mixtral-8x22b-instruct-v0.1 (Rank #1 trong RAGAS leaderboard)
- **Temperature:** 0.0 để đảm bảo tính nhất quán

6.2 Cấu Hình Hệ Thống

- **Agent Type:** ReAct Agent
- **Main LLM:** meta/llama-3.1-70b-instruct
- **Retriever:** Milvus với nvidia/nv-embedqa-e5-v5

-
- **Top-k retrieval:** 3 documents
 - **Max tokens:** 512

6.3 Phân Tích Bộ Test

6.3.1 Bộ Test Gốc (questions.json)

Đặc điểm:

- **Nguồn tạo:** Claude
- **Số lượng:** 5 câu hỏi
- **Độ khó:** 3 easy, 2 medium
- **Loại:** document_lookup, data_analysis, statistical_analysis, regulation_lookup, excel_analysis

Kết quả tổng quan:

- **Average Score:** 1.0 (Perfect)
- **Phân bố điểm:** 1.0, 1.0, 1.0, 1.0, 1.0
- **Tỷ lệ thành công:** 100%

ID	Câu hỏi	Loại	Độ khó	Điểm	Phân tích
Q1	AIMS document topic	document_lookup	easy	1.0	Perfect retrieval và summarization
Q2	IT employee highest salary	data_analysis	easy	1.0	Excellent CSV parsing và comparison
Q3	Marketing department count	statistical_analysis	medium	1.0	Accurate counting từ structured data
Q4	Security regulations (Vietnamese)	regulation_lookup	medium	1.0	Good multilingual processing
Q5	Excel file content	excel_analysis	easy	1.0	Effective structured data analysis

Bảng 1: Kết quả chi tiết - Bộ Test Gốc

6.3.2 Bộ Test Nâng Cấp (questions2.json)

Đặc điểm:

- **Nguồn tạo:** Claude
- **Số lượng:** 5 câu hỏi
- **Độ khó:** 5 hard
- **Loại:** critical_analysis, advanced_statistical_analysis, comprehensive_workforce_analysis, compliance_security_analysis, advanced_data_quality_analysis

Kết quả tổng quan:

- **Average Score:** 0.35 (Low)
- **Phân bố điểm:** 0.25, 0.0, 1.0, 0.0, 0.5

- **Tỷ lệ thành công:** 20% (chỉ 1/5 câu đạt điểm tối đa)

Bảng 2: Kết quả chi tiết - Bộ Test Nâng Cấp

ID	Câu hỏi	Loại	Độ khó	Điểm	Vấn đề chính
Q1	AIMS methodology vs AI standards	critical_analysis	hard	0.25	Thiếu external knowledge, shallow analysis
Q2	Salary variance calculation	advanced_statistical_analysis	hard	0.0	Không có mathematical tools, no actual calculations
Q3	Comprehensive workforce analysis	comprehensive_workforce_analysis	hard	1.0	Success: synthesize multiple metrics
Q4	ISO 27001 compliance (Vietnamese)	compliance_security_analysis	hard	0.0	Critical agent format parsing error
Q5	Data quality assessment	advanced_data_quality_analysis	hard	0.5	Surface-level analysis, missing deep insights

6.4 Tóm tắt phân tích so sánh

6.4.1 Điểm mạnh đã được xác nhận

- Hiệu suất rất tốt đối với các tác vụ tra cứu và phân tích cơ bản
- Khả năng truy xuất tài liệu chính xác khi truy vấn rõ ràng

-
- Có thể xử lý đa ngôn ngữ (bao gồm tiếng Việt) ở mức chấp nhận được

6.4.2 Điểm yếu được bộc lộ

- Mô hình tác tử (agent) thiếu ổn định khi phải xử lý chuỗi suy luận phức tạp
- Hoàn toàn thiếu năng lực toán học và thống kê
- Phân tích còn nông, thiếu chiều sâu trong các tác vụ phức tạp
- Không có tri thức chuyên ngành tích hợp sẵn


6.4.3 Ngưỡng độ khó được xác định

- Vùng hiệu quả: câu hỏi dễ đến trung bình (mức độ phức tạp $\leq 7/10$)
- Điểm suy giảm: câu hỏi khó yêu cầu phân tích nhiều bước
- Thất bại nghiêm trọng: các tác vụ cần công cụ chuyên biệt hoặc kiến thức miền chuyên sâu

7 Demo UI

Demo test file (.csv)

```
Name, Age, Department, Salary, Email
Nguyen Van A, 28, IT, 15000000, nguyenvana@company.com
Tran Thi B, 32, Marketing, 12000000, tranthib@company.com
Le Van C, 25, Finance, 13000000, levanc@company.com
Pham Thi D, 30, HR, 11000000, phamthid@company.com
Hoang Van E, 35, IT, 18000000, hoangvane@company.com
Vo Thi F, 27, Marketing, 14000000, vothif@company.com
Do Van G, 29, Finance, 16000000, dovang@company.com
Bui Thi H, 31, IT, 17000000, buithih@company.com
Mai Van I, 26, HR, 10000000, maivani@company.com
Dang Thi J, 33, Marketing, 15500000, dangthij@company.com
```



Hình 4: Demo UI

8 Kết luận

Hệ thống RAG hiện tại hoạt động rất tốt đối với các tác vụ tra cứu thông tin cơ bản và phân tích đơn giản, nhưng bộc lộ nhiều hạn chế nghiêm trọng khi phải xử lý các yêu cầu phân tích phức tạp. Sự khác biệt 65% về hiệu suất giữa hai bộ test cho thấy rõ ràng những giới hạn về mặt kiến trúc, đồng thời chỉ ra các điểm cần được cải thiện ngay lập tức để hệ thống có thể đạt tới năng lực phân tích ở cấp độ doanh nghiệp.

Mô hình đánh giá (Judge LLM) Mixtral 8x22B cung cấp kết quả đánh giá nhất quán và đáng tin cậy, xác nhận rằng khoảng cách hiệu suất phản ánh đúng giới hạn của hệ thống, chứ không phải do thiên lệch trong quá trình đánh giá.